

Parrot 14 기 ML 프로젝트

뉴스 기사 인기 예측








평가지표 : PR-AUC | 최고점수 : 0.338

INDEX

목차

01 전처리 과정

02 모델 선정 및 튜닝

03 결과 해석

04 어려웠던 점 & 한계 및 개선 방향

01

전처리 과정

결측치 · 이상치 · 다양한 변환 시도 및 최종 결론

데이터 기본 현황

결측치 처리

Train 데이터	23,644 건
Test 데이터	8,000 건
결측치	0 개
상수 컬럼	없음

처리할 결측치 따로 존재하지
않음 !

이상치 처리

⚠️ 비율형 피처 이상값 발견

n_unique_tokens
n_non_stop_words / n_non_stop_unique_tokens

정상 범위 : 0~1 / 이상값 : 최대 700 이상

해결 방법

→ clip(0, 1) 처리 적용
→ 피처 범위를 0~1 로 강제 제한
→ IQR 기반 이상치 처리

→ 이후 원본 데이터 그대로 사용 결정

전처리 변환 시도 결과 비교

다양한 변환을 시도했지만 원본 데이터가 가장 좋은 성능을 보였다

log 변환

시도 내용

스케일 큰 피처 6 개
log 변환 적용
(kw_max_avg 등)

이유

일부 상관관계 향상
num_imgs/hrefs 는 오히려 하락
전체 성능 저하

❌ 점수하락 0.335

분위수 변환

시도 내용

kw_avg_avg, kw_max_avg
정규분포 변환 적용

이유

이론상 상관관계 향상
(0.088→0.172)
실제 모델 성능은 하락

❌ 점수하락 0.335

원본 그대로

시도 내용

전처리 변환 없이
원본 58 개 피처
그대로 사용

이유

트리 모델은 스케일 불변
이미 잘 정제된 데이터
변환이 오히려 정보 손실

✅ 최고성능 0.338

왜 원본 데이터가 가장 좋았나 ?

1

트리 모델은 스케일에 불변

LightGBM·XGBoost·CatBoost 는 분기점을 기준으로 학습함 .
수치의 절대 크기가 아닌 대소 관계만 중요하기 때문에 log 변환이나 정규화가 성능에 영향을 주지 않음 .

2

이미 잘 정제된 파생 피처

kw_avg_avg, LDA_03 등 상위 피처들은 이미 계산된 파생 피처임 .
원본 데이터 자체가 충분히 정제되어 있었기 때문에 추가 변환이 오히려 피처의 정보를 손실시킴 .

3

변환 시 일부 피처 정보 손실

분위수 변환 시 num_imgs 는 0.079→0.011, num_hrefs 는 0.073→0.021 로 급락 .
상관관계가 올라가는 피처가 있어도 내려가는 피처가 더 많았기 때문에 전체 모델 성능은 오히려 하락함 .

02

모델 선정 및 튜닝

단일 모델에서 3 개 앙상블로 선택하게 된 과정 & 하이퍼 파라미터 선정 과정

단일 모델 → 앙상블로 선택한 계기

1 — 2 — 3 — 4

STEP 01	STEP 02	STEP 03	STEP 04
랜덤포레스트	XGBoost 단일	LGB + XGB	LGB+XGB+CAT
PR-AUC 0.31	PR-AUC 0.327	PR-AUC 0.337	PR-AUC 0.338
처음 시도한 모델 단순하지만 과적합 발생 성능 한계 명확	부스팅 계열로 교체 성능 향상 확인 하지만 여전히 한계	두 모델 앙상블 서로 약점 보완 +0.01 향상 확인	CatBoost 추가 학습 방식 다양화 현재 최고 성능

3 개 모델 특성 비교

LightGBM
Leaf-wise 방식

- ✓ leaf-wise: 깊은 트리 빠르게 성장
- ✓ is_unbalance=True: 불균형 자동 처리
- ✓ 학습 속도 가장 빠름
- ✓ average_precision 평가지표 직접 최적화

XGBoost
Level-wise 방식

- ✓ level-wise: 균형 잡힌 안정적 트리
- ✓ scale_pos_weight=4.95: 불균형 처리
- ✓ PR_AUC 평가지표 직접 최적화
- ✓ 과적합에 강한 정규화

CatBoost
Symmetric 방식

- ✓ symmetric 트리 : 과적합 강함
- ✓ PR_AUC 평가지표로 직접 최적화
- ✓ auto_class_weights=Balanced
- ✓ Optuna 튜닝 후 가중치 0.63 획득

튜닝 전략 **및 성능 향상**

Optuna 핵심 전략

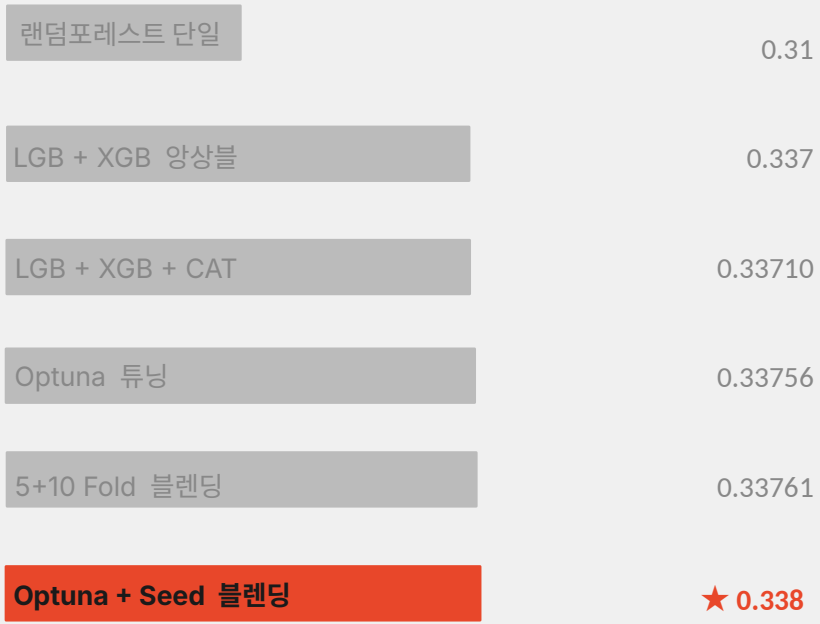
① 탐색 범위 좁히기

learning_rate: 0.01~0.1 → 0.01~0.05
기존 최적 파라미터 주변만 정밀 탐색
→ 같은 25 번 시도도 효율이 2 배 상승

② enqueue_trial 시작점 등록

기존 최고 파라미터 (0.337) 를 첫 시도로 고정
Optuna 가 처음부터 최적점 근처를 탐색
방향 낭비 없이 0.338 달성

단계별 성능 향상

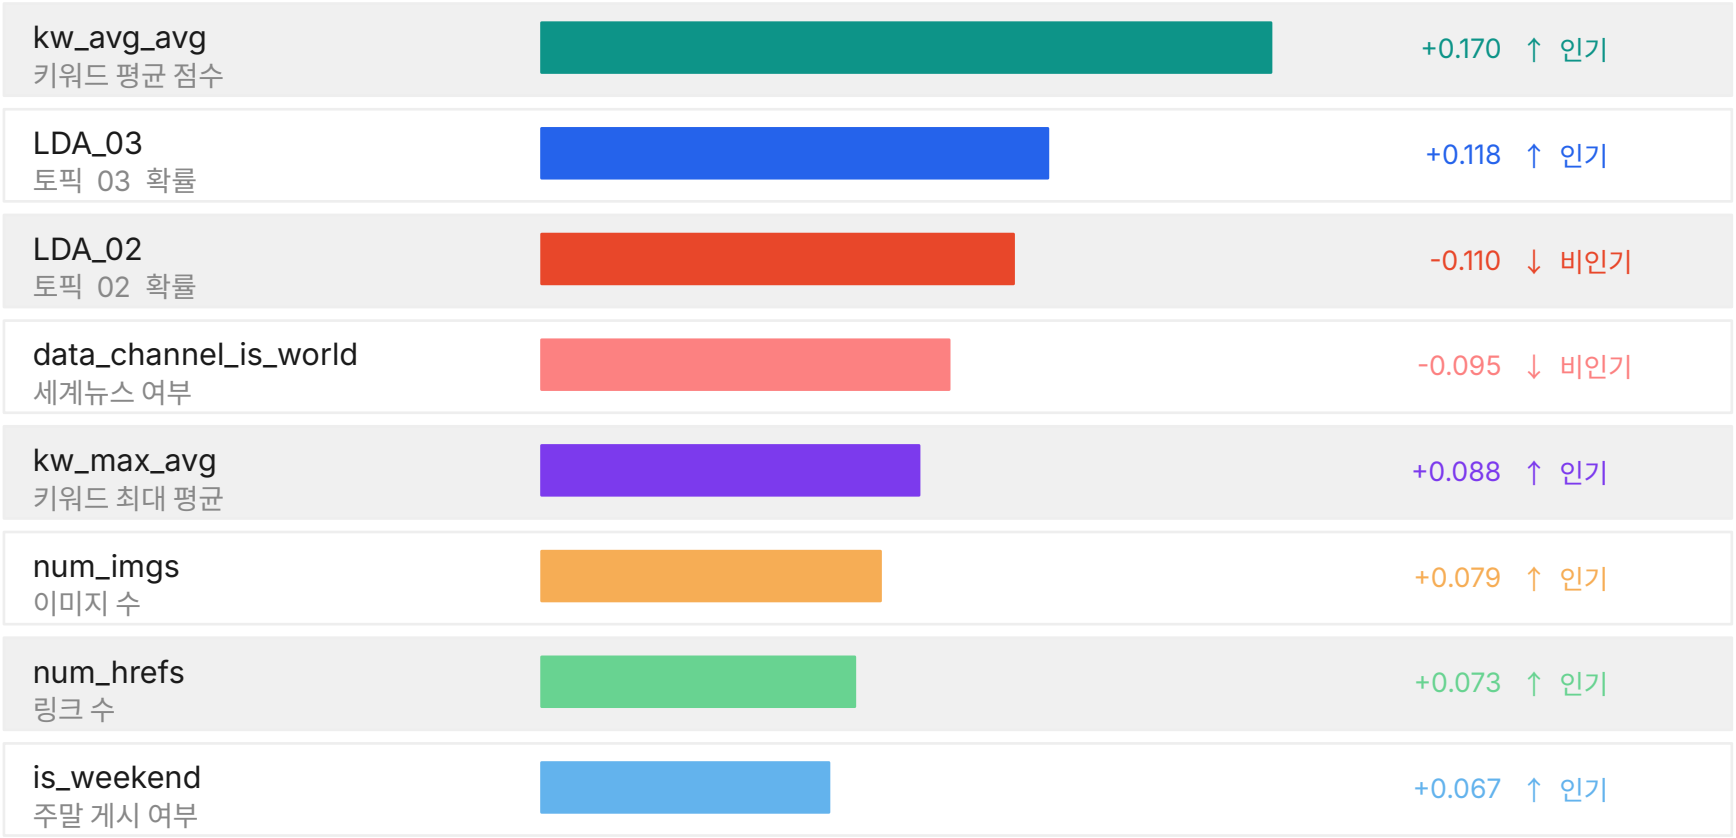


03

결과
해석

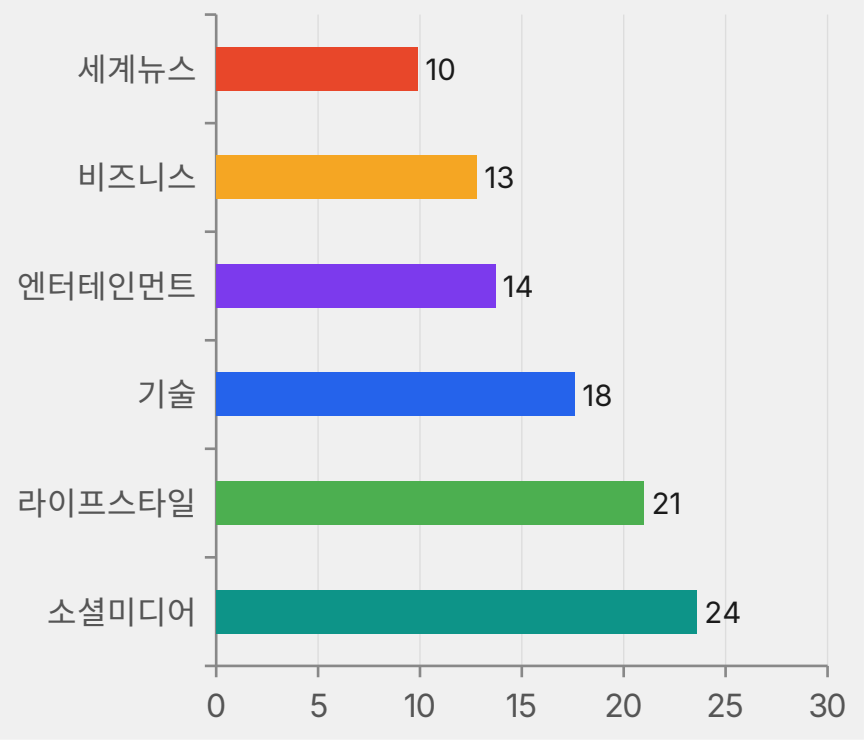
중요 피처 분석과 인기 기사 패턴 인사이트

중요 피처 분석 (target 상관관계)



인사이트 - 인기 기사 패턴

채널별 인기율



🔑 키워드 품질이 핵심

상위 20% 인기율 29.6% vs 하위 20% 9.6%
→ 키워드가 좋으면 3 배 이상 인기

📅 주말 효과

주말 인기율 23.2% vs 평일 15.8%
→ 선택적 소비 경향 , 주말이 1.5 배

📸 이미지 · 링크 많을수록 인기

시각적 · 심층적 콘텐츠 선호
→ 풍부한 기사가 공유 잘 됨

04

어려웠던 점
& 한계 및 개선방향

문제 발견 → 시도 → 결론까지의 과정

어려웠던 점 & 해결 과정

01 📊 **전처리 과정이 큰 도움 안됨**

문제 전처리 과정을 진행할수록 점수가 저조함

해결 모델의 특성을 공부한 뒤에 원본 데이터를 그대로 사용하는 것이 효과적이라는 것을 깨달음

02 ⚠️ 코드 진행 시간의 증가

문제 코드 진행시간이 오래걸림

해결 Early Stopping 을 통해 학습 조기종료를 실현함
Optuna 탐색 범위를 좁힘

03 🔧 피처 엔지니어링 시도 및 포기 과정

문제 처음에 파생 피처를 추가했으나 큰 도움이 되지않음

해결 파생 피처와 원본 피처로 히트맵 분석을 통해 큰 차이를 도출하지 못해 , 원본 데이터를 사용하기로 결정

04 🎯 0.34 벽을 넘지 못함

문제 1위 (0.34008) 와 0.00235 차이에서 멈춤

개선방향 스태킹 앙상블을 바탕으로 새로운 모델을 구현하여 더 좋은 결과값을 얻어보고싶음

Thank You

감사합니다

뉴스 기사 인기 예측 — Parrot 14 기 ML 프로젝트

모델	전략	최고 점수
LGB + XGB + CatBoost	Optuna + Seed 블렌딩	0.338 PR-AUC